Graves Sacha 22307269
Destrade Charles 22401060

L2 MIASHS - 2025
Science des données
Enseignante : Nefissa Khiari

Classification supervisée et non supervisée pour l'analyse des émotions à partir de tweets

Résumé

Pour trouver notre jeu de données, nous sommes allés sur Kaggle, puis avons cherché des jeux de données qui peuvent contenir une colonne de donnée textuelles et une colonne de données quantitatives discrètes. Pour cela, nous avons pensé qu'un jeu de données sur des tweets pourrait correspondre. Nous avons donc trouvé notre jeu de données sur Kaggle, en tapant les mots-clés emotion et tweet dans la barre de recherche des jeux de données Kaggle.

Ce jeu de données compte deux colonnes, la première regroupe les tweets, qui sont uniquement des phrases d'utilisateurs. La deuxième colonne indique un numéro de 0 à 4 avec l'émotion principale qui correspond à ce tweet. 0-tristesse ; 1- joie ; 2-amour ; 3-colère ; 4-peur. La variable étudiée est donc textuelle et de taille variable, il peut y avoir des tweets qui font 3 mots et d'autres de plusieurs phrases.

Pour trier les données et conserver seulement 150 lignes de données. Nous avons copié et collé les 30 premières lignes correspondant à chaque modalités de sentiment dans un nouveau fichier tableau csv. Cela nous faisait un total de 151 lignes de données en comptant l'en-tête. Notre fichier compte donc 30 lignes de données pour chaque sentiment associé.

Dans l'apprentissage non supervisé, nous avons appliqué des techniques de clustering pour regrouper les textes en fonction de leur similarité intrinsèque. L'objectif est d'observer si les groupes formés par les algorithmes reflètent les émotions présentes dans les textes, même sans utiliser les étiquettes.

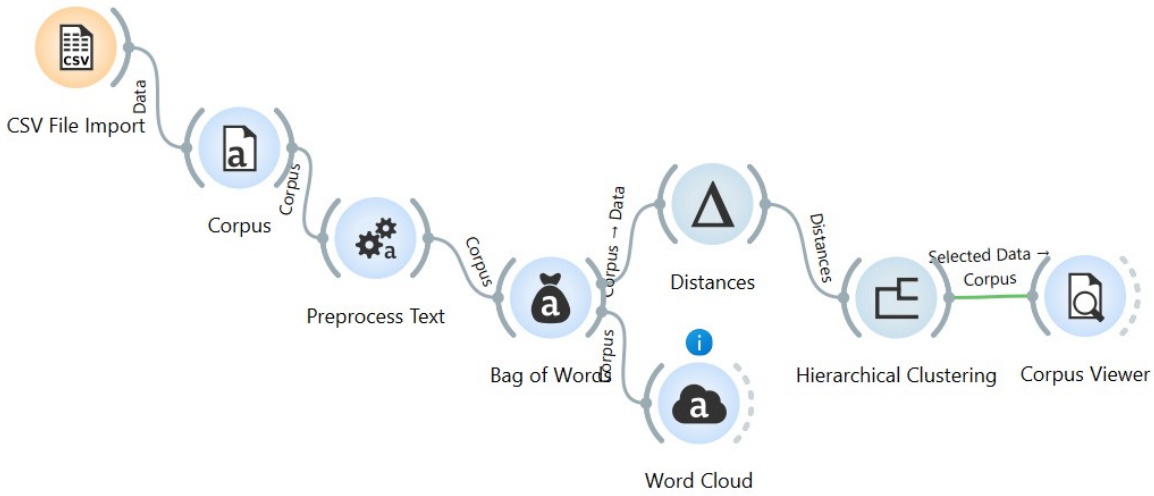
Dans l'apprentissage supervisé, nous avons utilisé les émotions comme labels afin d'entraîner différents modèles de classification. L'objectif est de prédire automatiquement l'émotion exprimée dans un texte. Pour cela, on a divisé le fichier CSV en deux fichiers; le premier ayant 24 tweets étiquetés par émotions qui servira d'entraînement et de test à nos modèles et le second avec 6 tweets par émotions sans les étiquettes qui nous servira à prédire ces dernières.

Table des matières

Apprentissage non supervisé.....4
1. Importation du fichier CSV.....4
2. Définition du corpus.....5
3. Prétraitement linguistique.....5
4. Vectorisation.....6
5. Visualisation du vocabulaire.....7
6. Mesure des distances.....7
7. Clustering hiérarchique.....8
8. Analyse qualitative des clusters.....8
Apprentissage supervisé.....11
1. Importation du fichier CSV.....11
2. Définition du corpus.....11
3. Prétraitement.....12
4. Vectorisation.....13
5. Visualisation du vocabulaire.....13
6. Entraînement des modèles.....13
7. Évaluation pour connaître le meilleure modèle à prendre.....14
8. Prédiction.....15
9. Interprétation.....16

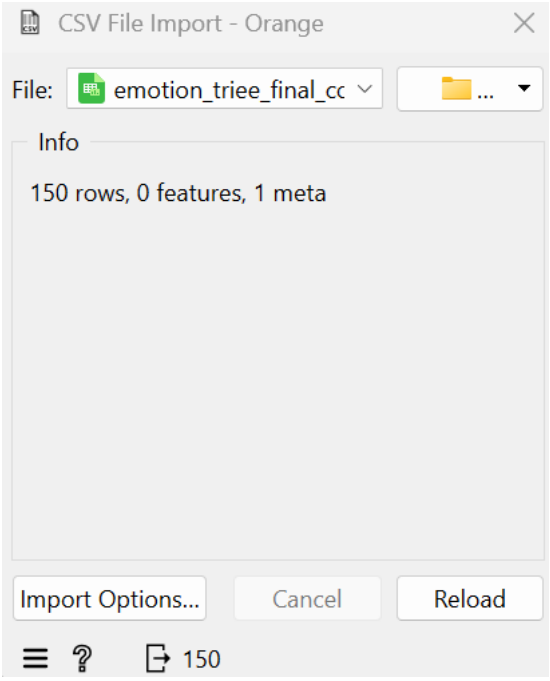
Apprentissage non supervisé

Pour le nettoyage et prétraitement, une suite complète d'instructions de préparation textuelle a été mis en place dans Orange, constitué des étapes suivantes :



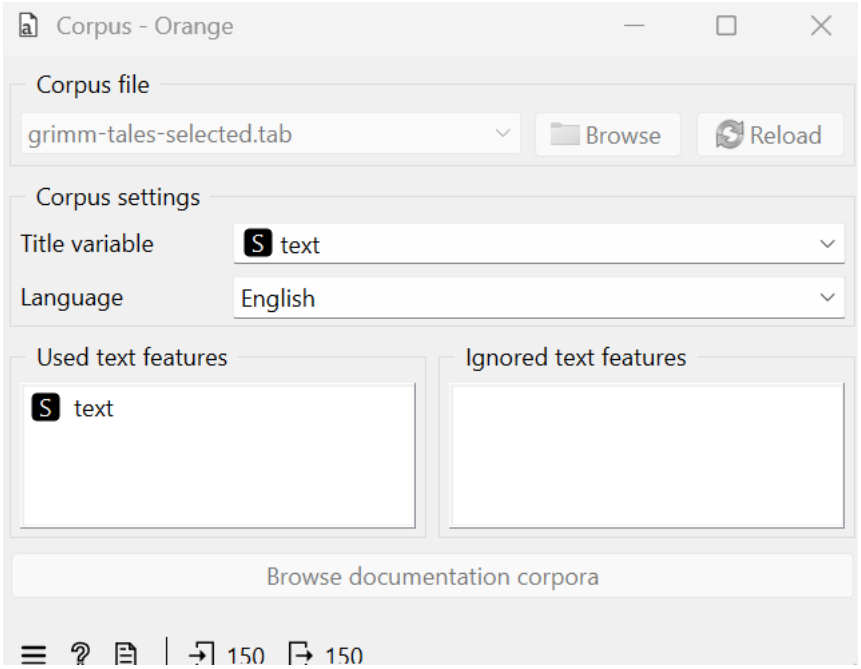
1. Importation du fichier CSV

- Module : *CSV File Import*
- Chargement de la colonne "tweet" comme texte principal



2. Définition du corpus

- Module : *Corpus*
- Conversion automatique des tweets en un corpus textuel Orange



3. Prétraitement linguistique

- Module : *Preprocess Text*
- Opérations appliquées :

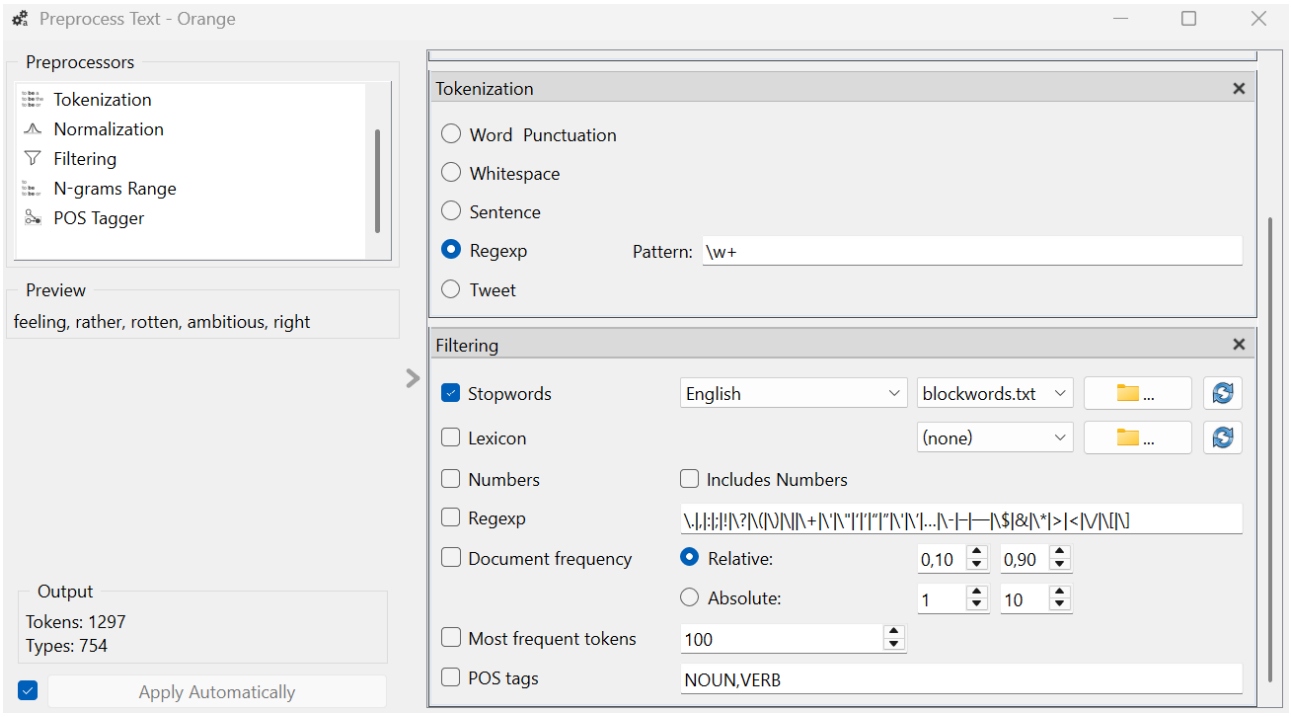
  - mise en minuscules

  - suppression de la ponctuation

  - import d'un fichier stopwords personnalisés, qui est partagé dans le zip en tant que blockwords.txt

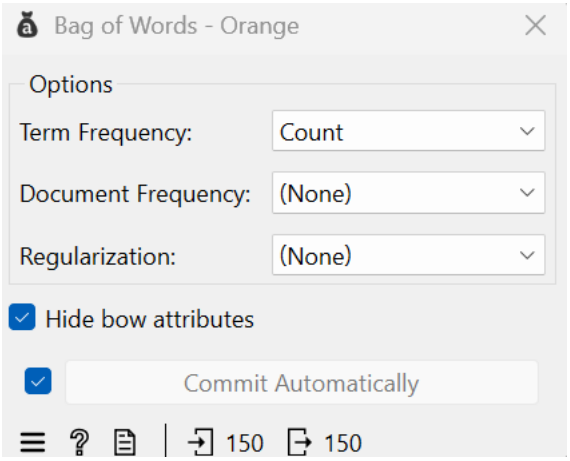
  -suppression des tokens trop courts ou non alphabétiques

Cette étape vise à réduire le bruit et homogénéiser les textes



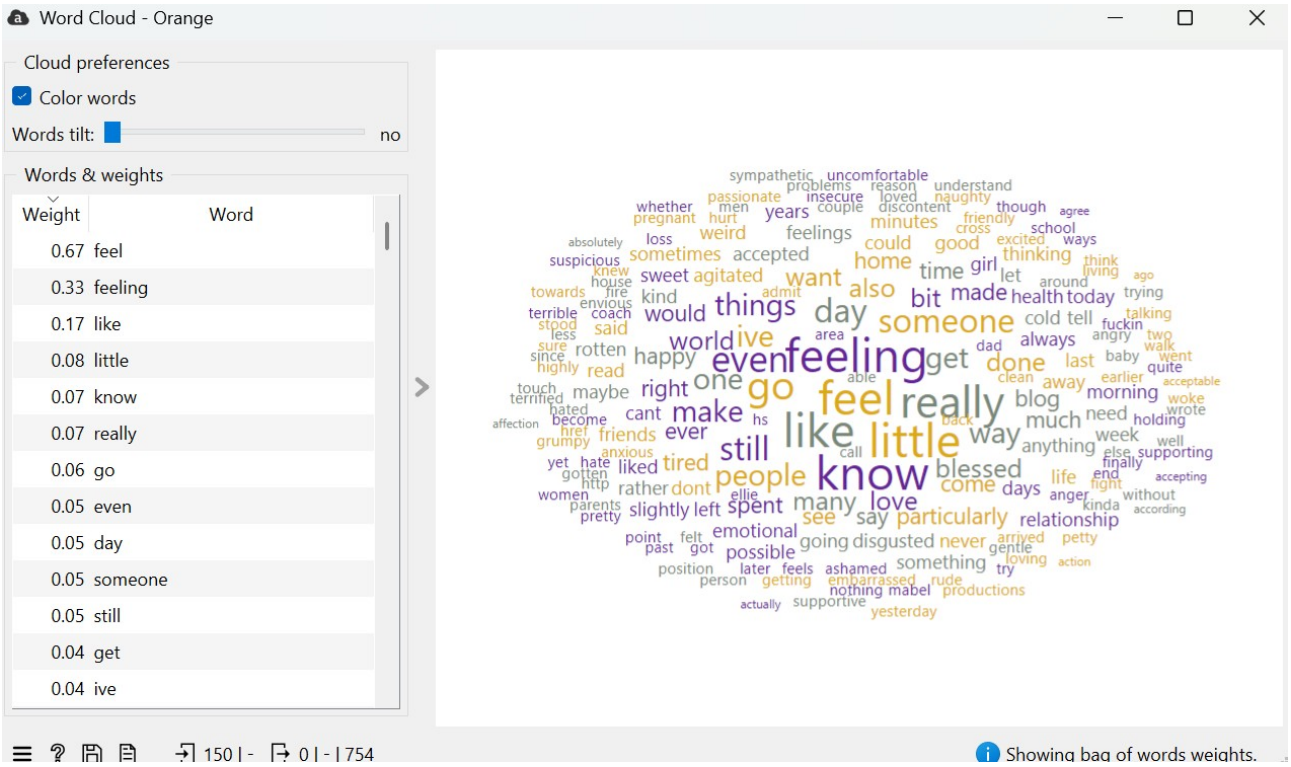
4. Vectorisation

- Module : *Bag of Words*
- Production d'une matrice documents des termes
- Pondération. Cela permet de transformer les textes en vecteurs numériques



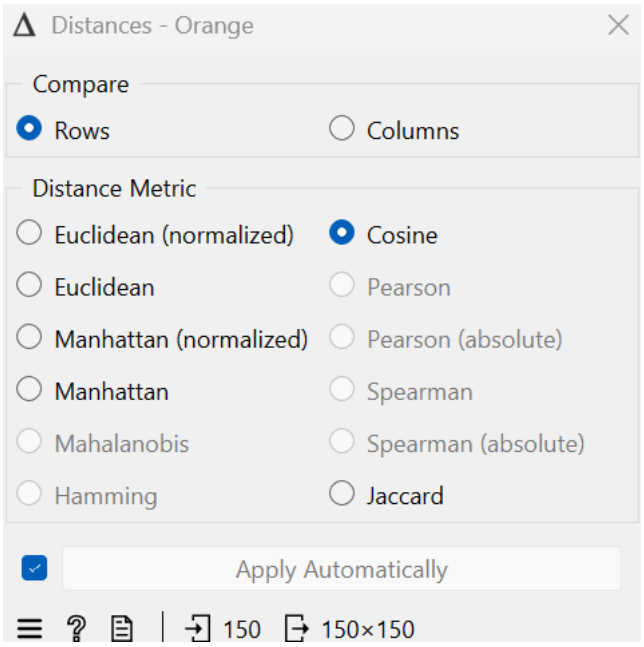
5. Visualisation du vocabulaire

- Module : *Word Cloud* (optionnel)
- Utilisé pour repérer rapidement les termes dominants du corpus.



6. Mesure des distances

- Module : *Distances*
- Calcul des distances entre vecteurs avec cosinus
  Cette matrice de distance sert d'entrée pour le clustering.



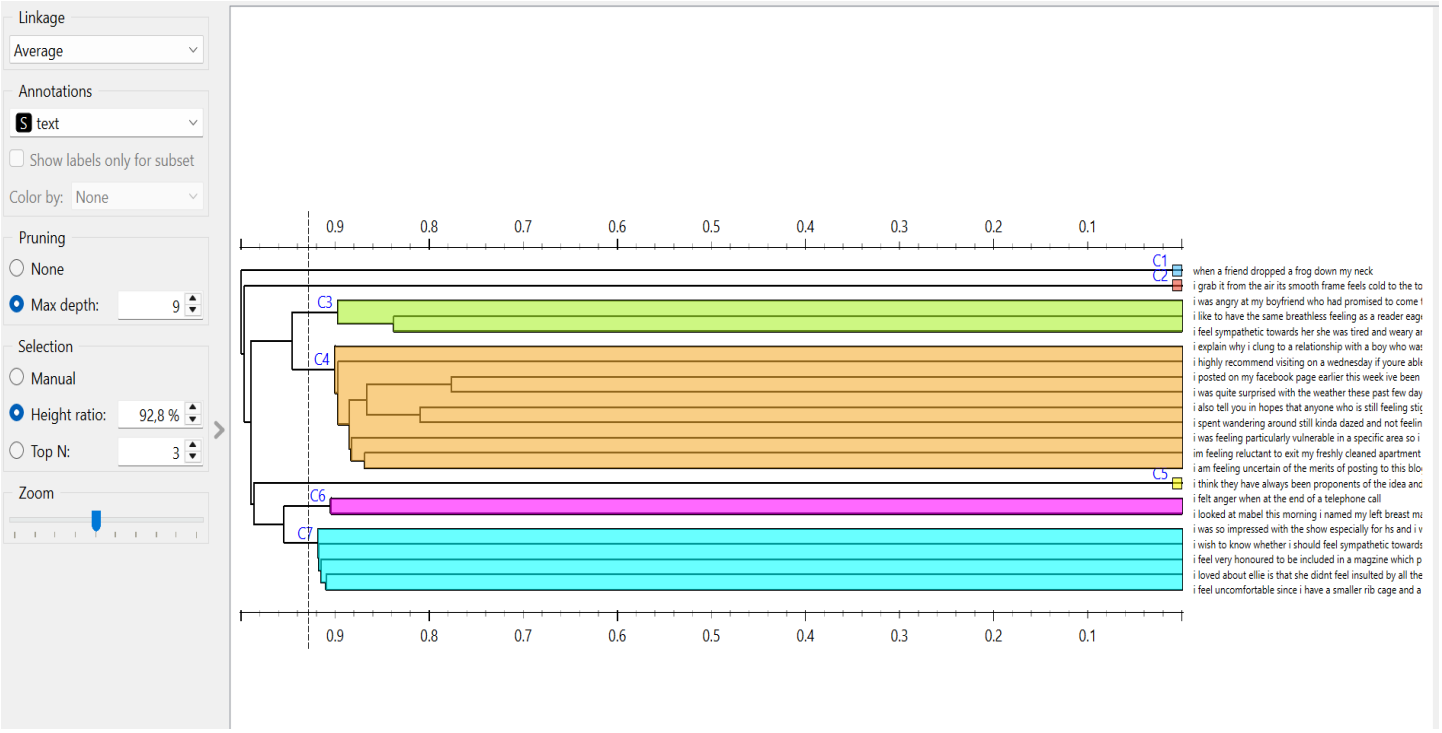
7. Clustering hiérarchique

- Module : *Hierarchical Clustering*
- Paramètres :

  - Méthode d'agrégation : Average

  - Nombre de clusters fixé à 7. Nous obtenons 4 familles principales et 3 sous familles. Cela confirme que le corpus contient plusieurs thématiques dominantes, mais aussi des tweets très spécifiques difficiles à regrouper.

  Bien qu'il y ait 4 familles principales, les 2 plus gros clusters sont C7 et C4.



8. Analyse qualitative des clusters

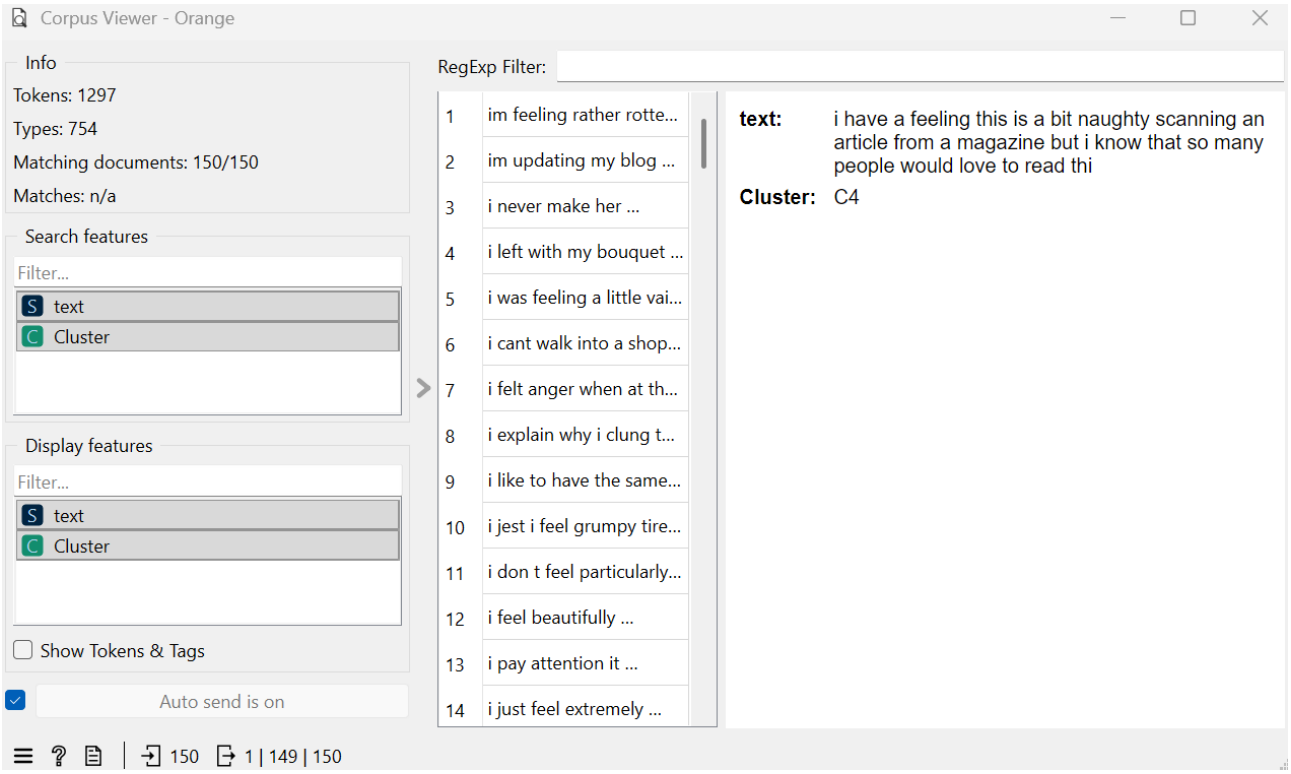
- Module : *Corpus Viewer*
- Affiche pour chaque cluster :

  - les tweets regroupés

  - les mots clés les plus discriminants

  - les structures linguistiques dominantes

Cette chaîne de traitement garantit la reproductibilité des résultats.



En ouvrant, des tweets répertoriés dans la famille C7, on observe que ces tweets contiennent les mots clefs ‘I’ et ‘ feel’. Ces tweets sont également de taille variées. Beaucoup de tweets commencent par ‘I am feeling’, mais l’algorithme ne répertorie pas ces tweets dans le cluster C7. Il semble donc qu’il y ait une différence entre ‘I feel’ et ‘I am feeling’ selon l’algorithme. Donc, les tweets de ce cluster sont de taille variable mais possèdent une caractéristique commune, ils ont tous les mots ‘I’ et ‘feel’.

Le cluster C4 est plus ou moins similaire au cluster C7, il regroupe tous le tweets où le verbe ‘feel’ est conjugué au temps B + ing. Au sens plus général, ce cluster répertorie les tweets où une forme de type B + ing est visible et peut importe le verbe conjugué. De plus, la taille moyenne d’un tweet de ce cluster est plus grande que dans le groupe C7, ceci est possiblement dû au fait qu’une phrase commençant par ‘I am feeling’ nécessite une plus longue explicitation ensuite.

Le cluster C3 regroupe 3 tweets. 2 qui n’ont ni le lemme ‘feel’ ni une phrase conjuguée au temps Be + ing. En revanche, un tweet attire notre attention : « i feel sympathetic towards her she was tired and weary and i can see how a split second doubt could make the effortless action of standing still seem like the better option » . Ce tweet commence par ‘I feel’ mais ne se trouve pas dans le cluster C7. Deux hypothèses s’offrent à nous : Soit le système algorithmique a une petite faille, soit notre interprétation derrière la regroupement par cluster est faux. De toute manière, l ‘échantillon est trop petit pour connaître à coup sûr la logique du recensement des tweets du hierarchical clustering.

Le cluster C1 ne possède qu'un seul tweet, 'When a friend dropped a frog down my neck'. Ce tweet est plutôt court, on observe qu'il n'y a pas de verbe conjugué au présent et qu'il n'y a ni le mot 'I' ni le lemme de 'feel'.

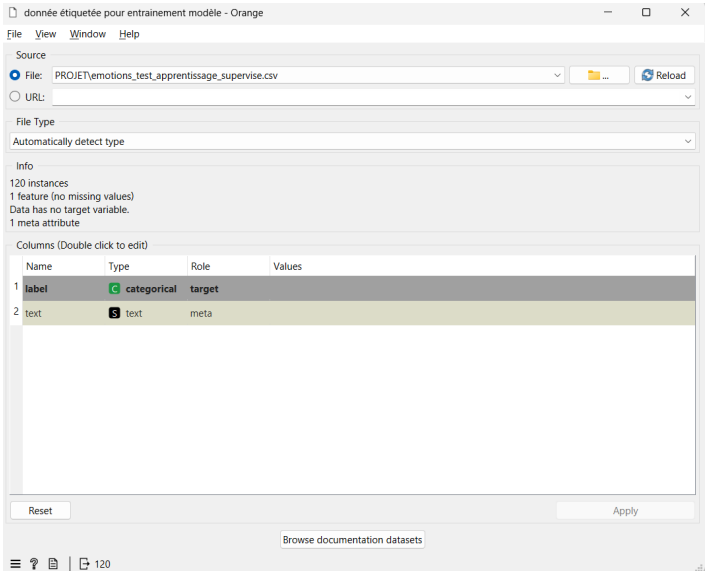
Similairement au cluster C1, les clusters C2 et C5 ne possèdent qu'un seul tweet sans verbe feel et sans forme Be + ing. C2 : « i grab it from the air its smooth frame feels cold to the touch » . C5 : « i think they have always been proponents of the idea and it is just slightly possible that his feelings for a particularly charming new england girl have brought him around to their way of thinking ». Ces trois tweets font donc partie de cluster isolés et sans point communs assez significatifs selon l'algorithme avec un cluster plus important.

Le pipeline mis en place dans Orange a permis une analyse non supervisée robuste sur un ensemble de tweets. La division en 7 clusters a permis d'identifier quatre familles thématiques majeures et trois tweets isolés dont le contenu est hors norme. La chaîne de traitement est adaptée au text mining, et les résultats sont cohérents avec la nature du corpus.

Apprentissage supervisé

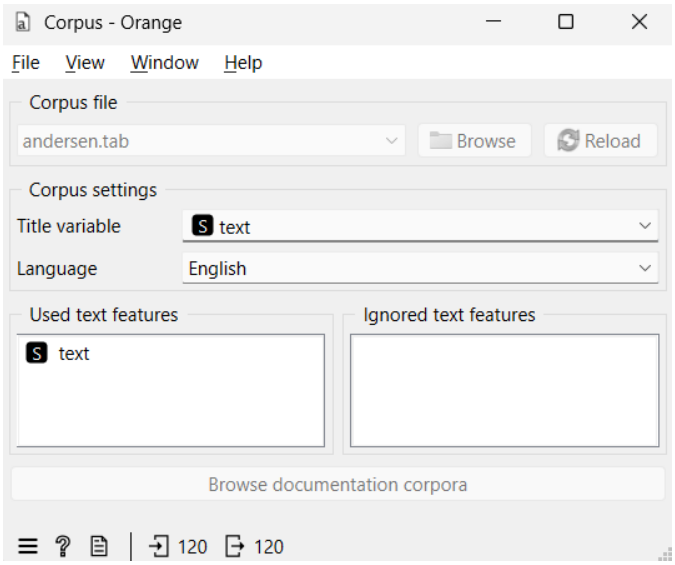
1. Importation du fichier CSV

- Module : File
- Chargement de la colonne “label” (label ; numéro correspondant aux différentes émotions) comme target



2. Définition du corpus

- Module : corpus
- Conversion automatique des tweets en un corpus textuel Orange



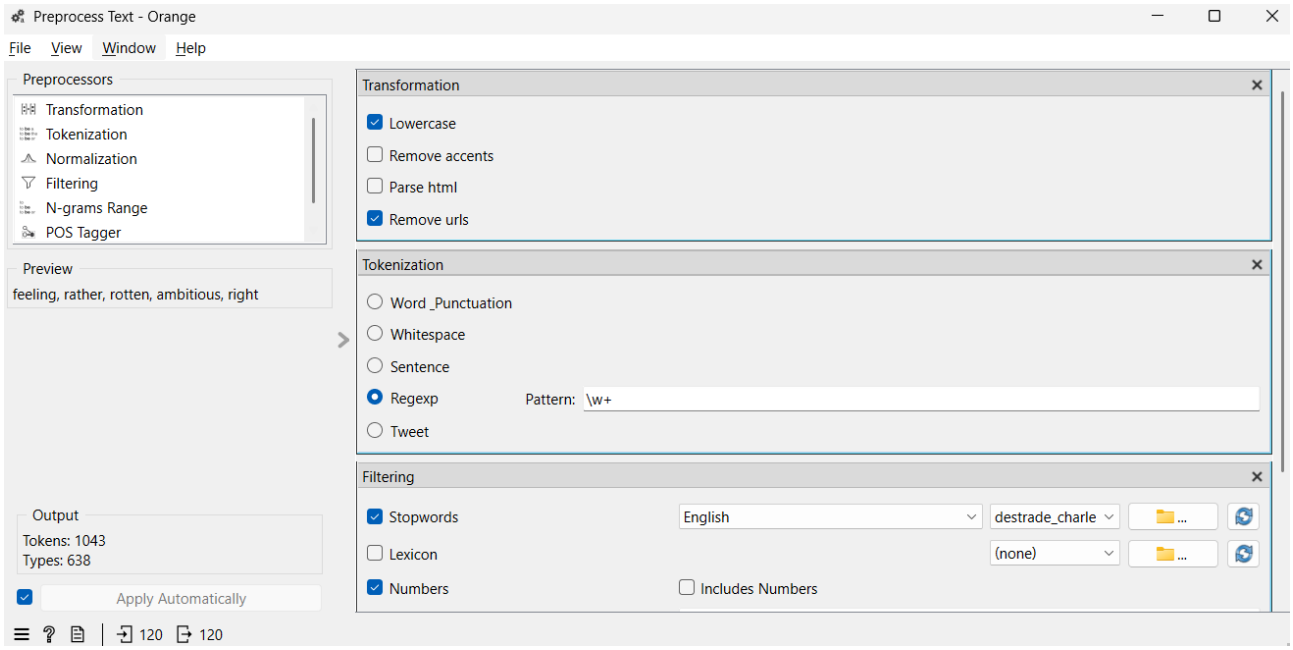
3. Prétraitement

- Module : Process Text
- Opérations appliquées :

  - mise en minuscules

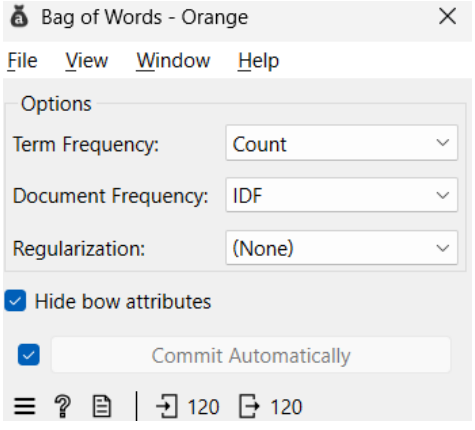
  - suppression de la ponctuation

  - import d'un fichier stopwords personnalisés, qui est partagé dans le zip en tant que destrade_charles_stopwords2.txt



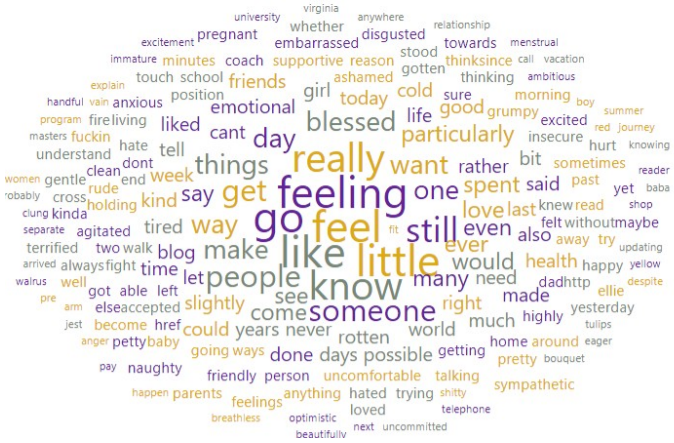
4. Vectorisation

- Module : *Bag of Words*
- Production d'une matrice documents des termes
- Pondération. Cela permet de transformer les textes en vecteurs numériques
- Nous avons activé TF-IDF dans le Bag of Words pour mieux valoriser les mots discriminants et réduire l'influence des termes trop fréquents.



5. Visualisation du vocabulaire

- Module : *Word Cloud* (optionnel)
- Utilisé pour repérer rapidement les termes dominants du corpus.



6. Entraînement des modèles

- Les modèles suivants ont été entraîné puis testé :

  - kNN

  - Neural Network

  - Naive Bayes

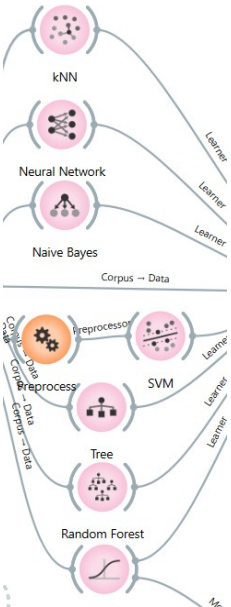
  - SVM (ajout d’un module preprocess pour normaliser les données, sinon panneau danger afficher sur Orange)

  - Tree

  - Random Forest

  - Logistic Regression

- Optimisation du kNN en modifiant « Number of neighbors »



7. Évaluation pour connaître le meilleure modèle à prendre

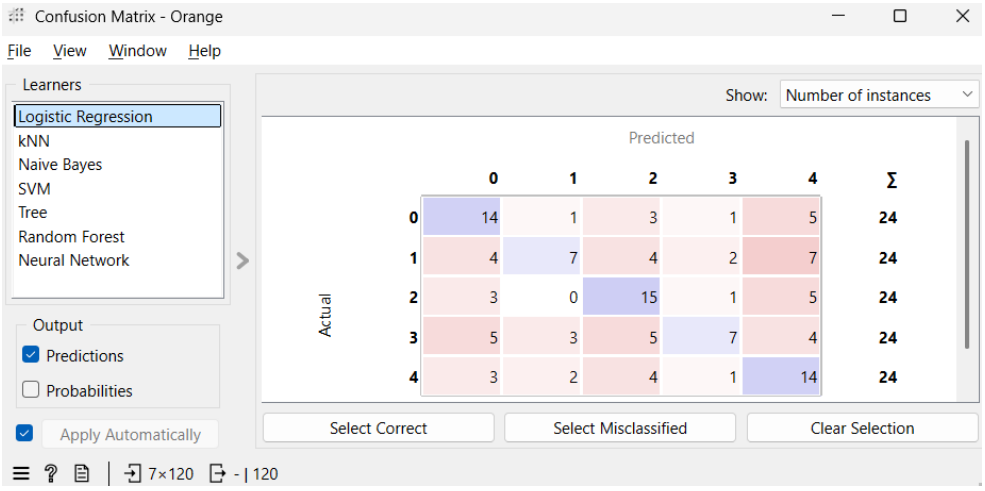
- Module : Test and Score
- Pour observer les scores des différents modèles
- Interprétation :

  - Logistic Regression a le meilleur accuracy, le meilleur recall, la deuxième meilleur précision et la meilleur f-mesure.

  Donc Logistic Regression est dans notre cas le meilleure modèle, alors nous utiliserons ce dernier pour la prédiction.
  - On peut observer tout les modèles sont mauvais. Même Logistic Regression a moins de 0,5 en recall, précision, et f-mesure. Les modèles sont très peu performant.

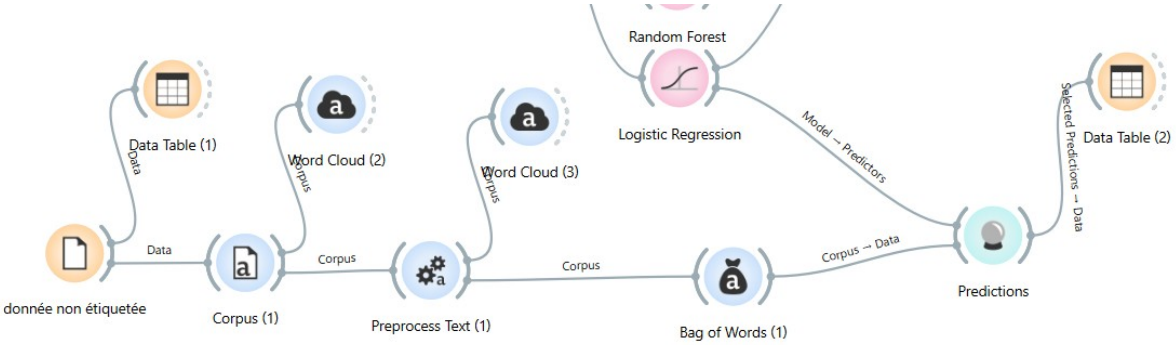
Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.729	0.475	0.463	0.498	0.475	0.351
kNN	0.581	0.283	0.216	0.315	0.283	0.133
Naive Bayes	0.678	0.358	0.303	0.516	0.358	0.218
SVM	0.549	0.192	0.178	0.239	0.192	-0....
Tree	0.574	0.292	0.268	0.338	0.292	0.127
Random Forest	0.599	0.325	0.319	0.338	0.325	0.161
Neural Network	0.719	0.383	0.377	0.393	0.383	0.233

- Module : Confusion Matrix
- Pour mieux, observer les résultats des différents modèles

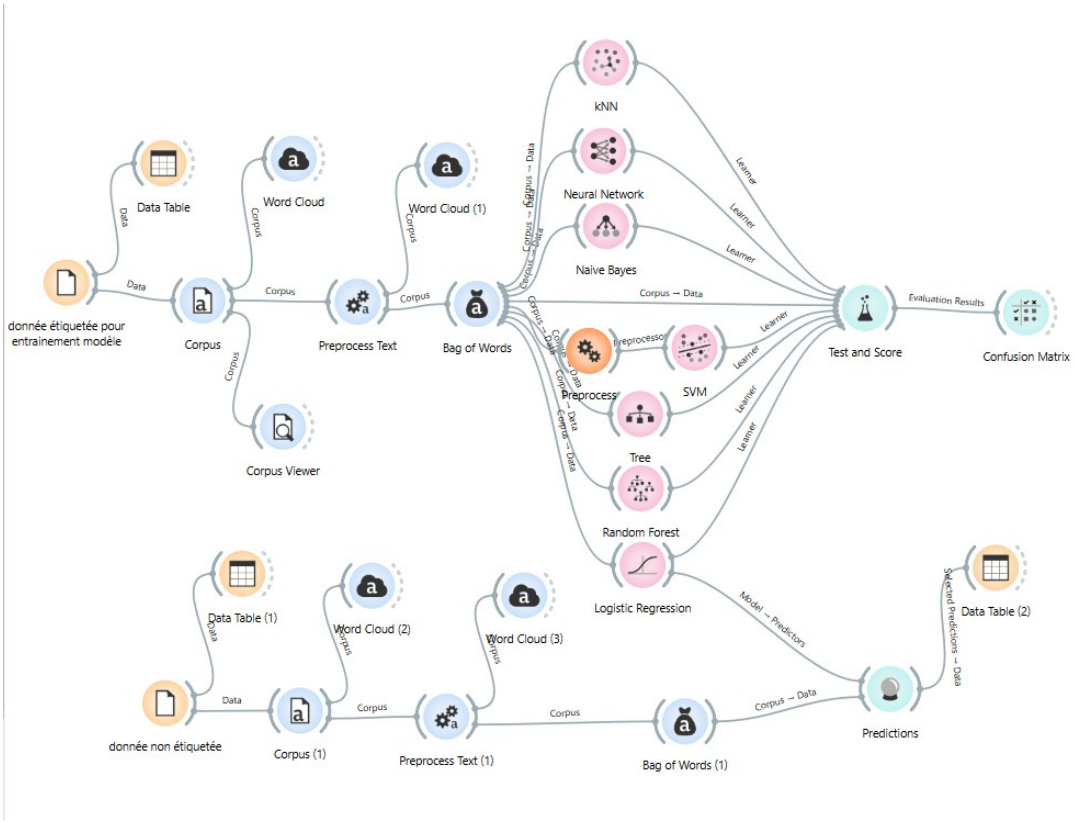


8. Prédiction

- Prédiction sur un autre fichier CSV sans les étiquettes (Dans notre cas 6 tweets pour chaque catégorie)
- Exactement le même procédé de prétraitement
- Ajout module Predictions
- Utilisation du modèle entraîné : Logistic Regression



- Chaîne Orange entière :



9. Interprétation

Les performances globales des modèles supervisés se sont révélées relativement faibles, notamment en termes d'accuracy, de précision, de rappel et de F-mesure. Ce qui indique une difficulté notable à distinguer correctement les différentes émotions à partir des tweets. Sur les 30 tweets destinés au test, le modèle n'a correctement prédit que 7 émotions, ce qui confirme la faiblesse générale des performances.

Plusieurs facteurs peuvent expliquer ces résultats :

- Les modèles supervisés nécessitent une quantité suffisante d'exemples pour apprendre des représentations stables. Avec seulement 30 tweets par émotion, il est difficile pour les algorithmes de saisir la richesse linguistique associée à chaque sentiment.

- Une forte variabilité dans la formulation des émotions, les tweets sont courts, hétérogènes, informels, parfois ambigus, et peuvent exprimer une émotion sans utiliser directement un vocabulaire affectif clair.

-Un déséquilibre implicite dans les données. Même si chaque émotion compte le même nombre d'exemples, les tweets n'expriment pas l'émotion de la même façon d'un individu à l'autre. Certaines émotions comme *peur* ou *amour* peuvent être moins explicites, ce qui gêne la séparation entre classes.

Même si différents modèles ont été testés beaucoup restent limités face aux textes courts.